UATF · Ingeniería Informática · INF672 Machine Learning

Segundo Parcial — Trabajo Práctico

Análisis de sentimiento de reseñas de cine con Regresión Logística

Gestión
II / 2026

01 Contexto y objetivo

En clase construimos un clasificador de noticias falsas: limpieza de texto, eliminación de stopwords, stemming, vectorización Bag of Words y Regresión Logística. En este trabajo aplicarás ese mismo proceso a un problema distinto: **predecir si una reseña de película es positiva o negativa** (análisis de sentimiento). No basta con copiar el notebook de clase: deberás adaptar cada etapa a los nuevos datos y justificar tus decisiones.

02 Conjunto de datos

IMDB Dataset of 50K Movie Reviews (Kaggle, autor lakshmi25npathi). Archivo único `IMDB Dataset.csv` con 50 000 reseñas en inglés, balanceadas entre ambas clases.

Columna	Descripción
`review`	Texto completo de la reseña escrita por un usuario (puede contener etiquetas HTML como ` `).
`sentiment`	Etiqueta de la reseña: `positive` o `negative`.

03 Tareas a desarrollar

In [1]

Carga y exploración

Lee el archivo y describe el conjunto de datos.

- Muestra la distribución de clases y verifica valores nulos y **reseñas duplicadas** (decide qué hacer con ellas).
- Calcula la longitud de las reseñas (en palabras) y compara su distribución entre ambas clases con un gráfico.

In [2]

Preprocesamiento del texto

Adapta la función de preprocesamiento vista en clase a este dataset.

- Inspecciona varias reseñas e identifica qué elementos "sucios" aparecen; elimina solo los que realmente existan.
- Las stopwords de NLTK incluyen palabras como `not`, `no` o `but`. Analiza si eliminarlas afecta a un problema de sentimiento y decide si las conservas. **Justifica tu decisión.**
- Trabaja inicialmente con una muestra de 5 000 reseñas y, si tu equipo lo permite, escala después.

In [3]

División de los datos

Separa los datos en entrenamiento (80 %) y prueba (20 %) con `train_test_split`, usando `stratify` y `random_state=42`.

- Explica por qué el vectorizador debe ajustarse (`fit`) solo con los datos de entrenamiento.

In [4]

Vectorización

Construye dos representaciones del texto y compáralas.

- **Modelo A:** Bag of Words con `CountVectorizer`.
- **Modelo B:** `TfidfVectorizer`. Investiga qué hace TF-IDF y explícalo con tus palabras en una celda Markdown.
- Experimenta con al menos un parámetro (`max_features`, `min_df` o `ngram_range`) y registra su efecto.

In [5]

Entrenamiento y evaluación

Entrena un modelo de `LogisticRegression` con cada representación y evalúalos sobre el conjunto de prueba.

- Reporta exactitud, precisión, recall y F1, y muestra la matriz de confusión de cada modelo.
- Resume los resultados en una tabla comparativa e indica qué modelo eliges y por qué.

In [6]

Interpretación del modelo

Analiza lo que aprendió tu mejor modelo.

- Muestra las 15 palabras con coeficientes más positivos y las 15 más negativos. ¿Tienen sentido?
- Escribe 3 reseñas propias (una claramente positiva, una negativa y una ambigua o sarcástica) y obtén su clase y probabilidad con `predict_proba`.
- Elige 2 reseñas del conjunto de prueba mal clasificadas y explica por qué crees que el modelo falló.

04 Entregables

- Enlace a GitHub de tu Notebook `Apellido_Nombre_P2_INF672.ipynb` ejecutado de principio a fin, sin errores, con todas las salidas visibles.
- Celdas Markdown que expliquen cada etapa, respondan las preguntas planteadas y cierren con una sección de **conclusiones**.
- Defensa en horario de clases.